

## Conferencia 4. Prueba de Hipótesis para dos Poblaciones

### Tema 2. Inferencia Estadística.

Sumario:

- Pruebas de hipótesis para la comparación de las medias de dos poblaciones Normales.
- Pruebas de hipótesis para la comparación de las varianzas de dos poblaciones Normales
- Pruebas de hipótesis para la comparación de las proporciones de dos poblaciones Binomiales.

#### 1. Introducción

En la práctica lo que más comúnmente se presenta son situaciones donde se poseen datos que provienen de dos o más muestras y se quieren comparar los valores de los parámetros de estas muestras.

Tal puede ser el caso que se le presenta a un investigador, cuando quiere probar que los valores de temperatura en una provincia del país son iguales a los de otra provincia, o la relación de la proporción de lluvia caída en unos meses con respecto a otros.

Para esto se realizan las pruebas de hipótesis con comparación de poblaciones.

#### 2. Dóctimas paramétricas

En este tipo de pruebas de hipótesis las dóctimas paramétricas están dadas en función de los valores de los parámetros de dos poblaciones.

Llamémosle  $\theta_1, \theta_2$  a los valores del parámetro  $\theta$  en la población 1 y 2 respectivamente, podemos entonces definir los planteamientos siguientes:

$$\begin{array}{c|c|c} \text{a.} & \text{b.} & \text{c.} \\ \hline \begin{array}{l} H_0: \theta_1 \leq \theta_2 \\ H_0: \theta_1 > \theta_2 \end{array} & \begin{array}{l} H_0: \theta_1 \geq \theta_2 \\ H_0: \theta_1 < \theta_2 \end{array} & \begin{array}{l} H_0: \theta_1 = \theta_2 \\ H_0: \theta_1 \neq \theta_2 \end{array} \end{array}$$

Basados en el criterio anterior se pueden encontrar las reglas de decisión adecuadas para los problemas de pruebas de hipótesis asociados a los parámetros  $\mu$  y  $\sigma^2$  de la distribución Normal, y el parámetro  $p$  de la distribución Binomial.

La teoría relacionada con las regiones críticas, errores y estadígrafos es análoga a las pruebas de hipótesis de una población.

#### 3. Pruebas de Hipótesis para la comparación de las medias de dos poblaciones Normales

##### a. Varianzas conocidas

Supongamos que se tienen dos muestras independientes  $X_1, \dots, X_{n_1}$  de  $X$  y  $Y_1, \dots, Y_{n_2}$  de  $Y$  de dos distribuciones normales de parámetros  $(\mu_1, \sigma_1^2)$  y  $(\mu_2, \sigma_2^2)$  respectivamente con  $\mu_1$  y  $\mu_2$  desconocidas y  $\sigma_1^2$  y  $\sigma_2^2$  conocidas, entonces se plantean las siguientes pruebas de hipótesis y sus respectivas reglas de decisión:

1. Hipótesis

$$\left| \begin{array}{l} H_0: \mu_1 \leq \mu_2 \\ H_1: \mu_1 > \mu_2 \end{array} \right| \left| \begin{array}{l} H_0: \mu_1 \geq \mu_2 \\ H_1: \mu_1 < \mu_2 \end{array} \right| \left| \begin{array}{l} H_0: \mu_1 = \mu_2 \\ H_1: \mu_1 \neq \mu_2 \end{array} \right|$$

2. Estadígrafo

$$Z = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

3. Región Crítica (RH<sub>0</sub>)

$$\left| \begin{array}{l} Z > Z_{1-\alpha} \\ Z < -Z_{1-\alpha} \\ |Z| > Z_{1-\frac{\alpha}{2}} \end{array} \right|$$

Ejemplo 1

Dos métodos de aprendizaje *A* y *B* deben ser comparados. De acuerdo con el criterio del especialista, el método *A* es superior al *B*. Dos muestras de 100 alumnos cada una, fueron seleccionadas aleatoriamente. Un grupo fue enseñado por el método *A* y el otro por el *B* y al final del período de aprendizaje los dos grupos fueron sometidos a un mismo examen. La puntuación promedio obtenida fue de 95 puntos para los del método *A* y 89 puntos para los del método *B*. De experiencias anteriores se sabe que estos métodos tienen varianzas de 5 y 4 respectivamente. Los datos justifican que se puede suponer una distribución Normal para las variables aleatorias *X* y *Y* que describen las calificaciones en el examen.

R/:

Datos:

$\mu_1$ : Calificación media poblacional usando *A*

$\mu_2$ : Calificación media poblacional usando *B*

$H_1$ : Método *A* superior al *B*

$\bar{X} = 95$

$\bar{Y} = 89$

$n_1 = n_2 = 100$

$\sigma_1^2 = 5$

$\sigma_2^2 = 4$

$$H_0: \mu_1 \leq \mu_2$$

$$H_1: \mu_1 > \mu_2$$

1. Fijo  $\alpha$   $\alpha = 0.05$

2. Estadígrafo

$$Z = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} = \frac{95 - 89}{\sqrt{\frac{5}{100} + \frac{4}{100}}} = \frac{6}{\sqrt{\frac{9}{100}}} = \frac{6}{\sqrt{0.09}} = \frac{6}{0.3} = 20$$

3. Región Crítica (RH<sub>0</sub>)

$$Z_{1-\alpha} = Z_{0.95} = 1.65$$

$$20 = Z > Z_{1-\alpha} = 1.65$$

4. Conclusión

Como  $20 > 1.65$  se rechaza  $H_0$ , por lo que se acepta que el método *A* es superior al *B* con un nivel de significación del 5%.

*b. Las varianzas son desconocidas pero iguales*

Supongamos que se tienen dos muestras independientes  $X_1, \dots, X_{n_1}$  de  $X$  y  $Y_1, \dots, Y_{n_2}$  de  $Y$  de dos distribuciones normales de parámetros  $(\mu_1, \sigma_1^2)$  y  $(\mu_2, \sigma_2^2)$  respectivamente con  $\mu_1$  y  $\mu_2$  desconocidas y  $\sigma_1^2$  y  $\sigma_2^2$  desconocidas pero iguales ( $\sigma_1^2 = \sigma_2^2$ ) entonces se plantean las siguientes pruebas de hipótesis y sus respectivas reglas de decisión:

1. Hipótesis

$$\left| \begin{array}{c|c|c} H_0: \mu_1 \leq \mu_2 & H_0: \mu_1 \geq \mu_2 & H_0: \mu_1 = \mu_2 \\ H_1: \mu_1 > \mu_2 & H_1: \mu_1 < \mu_2 & H_1: \mu_1 \neq \mu_2 \end{array} \right|$$

1. Estadígrafo

$$T_{\bar{X}-\bar{Y}} = \frac{\bar{X} - \bar{Y}}{\sqrt{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}} \sqrt{\frac{n_1 n_2 (n_1 + n_2 - 2)}{n_1 + n_2}}$$

2. Región Crítica (RH<sub>0</sub>)

$$\left| \begin{array}{c|c|c} T_{\bar{X}-\bar{Y}} > t_{1-\alpha}(n-2) & T_{\bar{X}-\bar{Y}} < -t_{1-\alpha}(n-2) & |T_{\bar{X}-\bar{Y}}| > t_{1-\frac{\alpha}{2}}(n-2) \end{array} \right|$$

Ejemplo 2.

Supongamos que en el ejemplo anterior no se conocen las varianzas, pero se sabe que son iguales.

Si  $S_1^2 = 5.1$   $S_2^2 = 4.9$ .

$$\begin{aligned} T_{\bar{X}-\bar{Y}} &= \frac{\bar{X} - \bar{Y}}{\sqrt{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}} \sqrt{\frac{n_1 n_2 (n_1 + n_2 - 2)}{n_1 + n_2}} \\ &= \frac{95 - 89}{\sqrt{99 * 5.1 + 99 * 4.9}} \sqrt{\frac{100 * 100 (100 + 100 - 2)}{100 + 100}} \\ &= \frac{6}{\sqrt{504.9 + 485.1}} \sqrt{\frac{10000(198)}{200}} = \frac{6}{\sqrt{990}} \sqrt{\frac{19800}{2}} = \frac{6}{31.46} \sqrt{9900} \\ &= 0.19 * 99.50 = 18.91 \end{aligned}$$

$$t_{1-\alpha}(n_1 + n_2 - 2) = t_{0.95}(198) \approx 1.65$$

$$18.91 = T_{\bar{X}-\bar{Y}} > t_{1-\alpha}(n_1 + n_2 - 2) = t_{0.95}(198) \approx 1.65$$

Como  $18.91 > 1.65$  se rechaza  $H_0$  por lo que se acepta que  $A$  es mejor que  $B$  con un nivel de significación del 5%, con una probabilidad de error de menor o igual a 0.05.

c. Las varianzas son desconocidas y diferentes

Supongamos que se tienen dos muestras independientes  $X_1, \dots, X_{n_1}$  de  $X$  y  $Y_1, \dots, Y_{n_2}$  de  $Y$  de dos distribuciones normales de parámetros  $(\mu_1, \sigma_1^2)$  y  $(\mu_2, \sigma_2^2)$  respectivamente con  $\mu_1$  y  $\mu_2$  desconocidas y  $\sigma_1^2$  y  $\sigma_2^2$  desconocidas y diferentes se plantean las siguientes pruebas de hipótesis y sus respectivas reglas de decisión:

1. Hipótesis

$$\left| \begin{array}{l|l|l} H_0: \mu_1 \leq \mu_2 & H_0: \mu_1 \geq \mu_2 & H_0: \mu_1 = \mu_2 \\ H_1: \mu_1 > \mu_2 & H_1: \mu_1 < \mu_2 & H_1: \mu_1 \neq \mu_2 \end{array} \right|$$

2. Estadígrafo

$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

3. Región Crítica (RH<sub>0</sub>)

$$\left| \begin{array}{l|l|l} T_{\bar{X}-\bar{Y}} > t_{1-\alpha}(v) & T_{\bar{X}-\bar{Y}} < -t_{1-\alpha}(v) & |T_{\bar{X}-\bar{Y}}| > t_{1-\frac{\alpha}{2}}(v) \end{array} \right|$$

$$v = \left( \frac{\left( \frac{S_1^2}{n_1} + \frac{S_2^2}{n_2} \right)^2}{\left( \frac{S_1^2}{n_1} \right) \frac{1}{n_1+1} + \left( \frac{S_2^2}{n_2} \right) \frac{1}{n_2+1}} \right) - 2$$

Ejemplo 3.

Supongamos que en el ejemplo anterior las varianzas son desconocidas y distintas. Entonces

$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} = \frac{95 - 89}{\sqrt{\frac{5.1}{100} + \frac{4.9}{100}}} = \frac{6}{\sqrt{\frac{10}{100}}} = \frac{6}{\sqrt{0.1}} = \frac{6}{0.32} = 18.75$$

Fijando  $\alpha = 0.05$  se tiene que  $t_{1-\alpha}(v) = t_{0.95}(v)$

$$\begin{aligned} v &= \left( \frac{\left( \frac{S_1^2}{n_1} + \frac{S_2^2}{n_2} \right)^2}{\left( \frac{S_1^2}{n_1} \right) \frac{1}{n_1+1} + \left( \frac{S_2^2}{n_2} \right) \frac{1}{n_2+1}} \right) - 2 = \frac{\left( \frac{5.1}{100} + \frac{4.9}{100} \right)^2}{\frac{5.1}{100} \frac{1}{100+1} + \frac{4.9}{100} \frac{1}{100+1}} - 2 \\ &= \frac{\left( \frac{10}{100} \right)^2}{\frac{5.1 + 4.9}{100(100+1)}} - 2 = \frac{(0.1)^2}{\frac{10}{10100}} - 2 = \frac{0.01}{0.00099} - 2 = 10.10 - 2 \approx 8 \end{aligned}$$

Por tanto  $t_{1-\alpha}(v) = t_{0.95}(v) = t_{0.95}(8) = 1.8595$

Como  $18.75 > 1.86$  se rechaza  $H_0$ , por lo que se acepta que  $A$  es mejor que  $B$  con un nivel de significación del 5%.

Qué pasaría si en los ejemplos 2 y 3 no conocemos las varianzas y tampoco conocemos si estas son iguales o diferentes. Pues sería necesario realizar primero una prueba de igualdad contra diferencia en las varianzas y en dependencia del resultado de la misma realizamos la prueba de medias con varianza desconocida correspondiente.

#### 4. Pruebas de Hipótesis para la comparación de las varianzas de dos poblaciones Normales.

Supongamos que se tienen dos muestras independientes  $X_1, \dots, X_{n_1}$  de  $X$  y  $Y_1, \dots, Y_{n_2}$  de  $Y$  de dos distribuciones normales de parámetros  $(\mu_1, \sigma_1^2)$  y  $(\mu_2, \sigma_2^2)$  respectivamente con  $\mu_1, \mu_2, \sigma_1^2$  y  $\sigma_2^2$  desconocidas entonces se plantean las siguientes pruebas de hipótesis y sus respectivas reglas de decisión:

$$\left| \begin{array}{l} H_0: \sigma_1^2 \leq \sigma_2^2 \\ H_1: \sigma_1^2 > \sigma_2^2 \end{array} \right| \left| \begin{array}{l} H_0: \sigma_1^2 \geq \sigma_2^2 \\ H_1: \sigma_1^2 < \sigma_2^2 \end{array} \right| \left| \begin{array}{l} H_0: \sigma_1^2 = \sigma_2^2 \\ H_1: \sigma_1^2 \neq \sigma_2^2 \end{array} \right|$$

##### 1. Estadígrafo

$$F = \frac{S_1^2}{S_2^2}$$

##### 2. Región Crítica (RH<sub>0</sub>)

$$\left| F > F_{1-\alpha}(n_1 - 1, n_2 - 1) \right| \left| F < F_{\alpha}(n_1 - 1, n_2 - 1) \right| \left| \begin{array}{l} F < F_{\frac{\alpha}{2}}(n_1 - 1, n_2 - 1) \text{ o} \\ F > F_{1-\frac{\alpha}{2}}(n_1 - 1, n_2 - 1) \end{array} \right|$$

Donde  $F_{\alpha}$  es el percentil de la distribución F de Fisher a nivel  $\alpha$

#### Ejemplo 4

Si en el ejemplo anterior se quiere analizar si puede aceptarse o no la igualdad de las varianzas de los métodos A y B entonces realizamos la prueba

$$\begin{aligned} H_0: \sigma_1^2 &= \sigma_2^2 \\ H_1: \sigma_1^2 &\neq \sigma_2^2 \end{aligned}$$

Tenemos que  $S_1^2 = 5.1$   $S_2^2 = 4.9$ .

##### 1. Fijo $\alpha$ $\alpha = 0.05$

##### 2. Estadígrafo

$$F = \frac{S_1^2}{S_2^2} = \frac{5.1}{4.9} = 1.04$$

##### 3. Región Crítica (RH<sub>0</sub>)

$$F_{\frac{\alpha}{2}}(n_1 - 1, n_2 - 1) = F_{\frac{0.05}{2}}(100 - 1, 100 - 1) = F_{0.25}(99, 99) = \text{No tenemos tabla}$$

Aplicamos Propiedad  $F_{\alpha}(n, m) = \frac{1}{F_{1-\alpha}(m, n)}$

En este caso  $F_{0.25}(99, 99) = \frac{1}{F_{1-0.25}(99, 99)} = \frac{1}{F_{0.75}(99, 99)}$  por desgracia tampoco contamos con la tabla de  $F_{0.75}$  que es Fisher al 25%.

$$F_{1-\frac{\alpha}{2}}(n_1 - 1, n_2 - 1) = F_{1-\frac{0.05}{2}}(100 - 1, 100 - 1) = F_{1-0.25}(99, 99) = F_{0.75}(99, 99)$$

En este caso tampoco contamos con la tabla de  $F_{0.75}$  que es Fisher al 25%. Por tanto no podemos continuar con el ejercicio puesto que no podemos aceptar ni Rechazar  $H_0$

### 5. Pruebas de Hipótesis para la comparación de proporciones de dos poblaciones Binomiales

Supongamos que se tienen dos muestras independientes  $X_1, \dots, X_{n_1}$  de  $X$  y  $Y_1, \dots, Y_{n_2}$  de  $Y$  donde  $X \sim B(n_1, p_1)$ ,  $Y \sim B(n_2, p_2)$ , entonces se plantean las siguientes pruebas de hipótesis y sus respectivas reglas de decisión:

	$H_0: p_1 \leq p_2$	$H_0: p_1 \geq p_2$	$H_0: p_1 = p_2$
1. <u>Estadígrafo</u>	$H_0: p_1 > p_2$	$H_0: p_1 < p_2$	$H_0: p_1 \neq p_2$

$$Z_{p_1 - p_2} = \frac{\bar{p}_1 - \bar{p}_2}{\sqrt{\frac{(n_1 \bar{p}_1 + n_2 \bar{p}_2)(n_1 + n_2 - n_1 \bar{p}_1 - n_2 \bar{p}_2)}{(n_1 + n_2)(n_1 * n_2)}}}$$

#### 2. Región Crítica (RH<sub>0</sub>)

$$\left| Z_{p_1 - p_2} > Z_{1-\alpha} \quad \left| Z_{p_1 - p_2} < -Z_{1-\alpha} \quad \left| Z_{p_1 - p_2} \right| > Z_{1-\frac{\alpha}{2}} \right| \right|$$

### Ejemplo 5

Dos grupos de 50 estudiantes fueron seleccionados aleatoriamente e interrogados acerca de la importancia de la Matemática. Los grupos se diferenciaban en el año escolar que estaban cursando (10mo y 11no grado). En el primer grupo, 30 estudiantes atribuyeron una importancia decisiva a las Matemáticas, mientras que en el segundo 25 estudiantes atribuyeron importancia similar. ¿Se puede afirmar que los estudiantes de 10mo grado atribuyen mayor importancia a la Matemática que los de 11no grado con un nivel de significación del 1%?

R/

Datos:

Sea  $X$ : número de estudiantes de 10mo grado que atribuyen importancia a la Matemática.

$$X \sim B(n_1, p_1)$$

$$n_1 = 50$$

$p_1$  desconocido.

Sea  $Y$ : número de estudiantes de 11no grado que atribuyen importancia a la Matemática.

$$Y \sim B(n_2, p_2)$$

$$n_2 = 50$$

$p_2$  desconocido.

Se tiene que:

$$\bar{p}_1 = \frac{30}{50} = 0.6$$

$$\bar{p}_2 = \frac{25}{50} = 0.5$$

$$\alpha = 0.01$$

Plateamos la siguiente hipótesis

$$H_0: p_1 \leq p_2$$

$$H_0: p_1 > p_2$$

$$\begin{aligned} Z_{p_1-p_2} &= \frac{\bar{p}_1 - \bar{p}_2}{\sqrt{\frac{(n_1 \bar{p}_1 + n_2 \bar{p}_2)(n_1 + n_2 - n_1 \bar{p}_1 - n_2 \bar{p}_2)}{(n_1 + n_2)(n_1 * n_2)}}} \\ &= \frac{0.6 - 0.5}{\sqrt{\frac{(50 * 0.6 + 50 * 0.5)(50 + 50 - 50 * 0.6 - 50 * 0.5)}{(50 + 50)(50 * 50)}}} \\ &= \frac{0.1}{\sqrt{\frac{(30 + 25)(50 + 50 - 30 - 25)}{100 * 2500}}} \\ &= \frac{0.1}{\sqrt{\frac{55(100 - 55)}{250000}}} \\ &= \frac{0.1}{\sqrt{\frac{55 * 45}{250000}}} \\ &= \frac{0.1}{\sqrt{\frac{2475}{250000}}} \\ &= \frac{0.1 \sqrt{250000}}{\sqrt{2475}} = \frac{0.1 \sqrt{250000}}{49.75} = \frac{0.1 * 500}{49.75} \\ &= \frac{50}{49.75} \\ &= 1.005 \end{aligned}$$

Como  $\alpha = 0.01$  entonces  $Z_{1-\alpha} = Z_{0.99} = 2.33$

Como  $1.005 < 2.33$  se rechaza  $H_0$ , por lo que los alumnos de 10<sup>mo</sup> grado conceden mayor importancia a las Matemáticas que los de 11<sup>no</sup> grado.